

МИНОБРНАУКИ РОССИИ

Федеральное государственное автономное образовательное
учреждение высшего образования
«Южный федеральный университет»

Институт математики, механики
и компьютерных наук им. И. И. Воровича

Кафедра математического моделирования

Агузарова Марина Георгиевна

**ПОСТРОЕНИЕ РЕКОМЕНДАТЕЛЬНОЙ СИСТЕМЫ
ТОВАРОВ НА ОСНОВЕ ДАННЫХ ОБ ОЦЕНКАХ
ПОЛЬЗОВАТЕЛЕЙ**

КУРСОВАЯ РАБОТА

по направлению подготовки

01.03.02 – Прикладная математика и информатика

Руководитель –

доцент., к. ф.-м. н. Пустовалова Ольга Геннадиевна

оценка (рейтинг)

подпись руководителя

Ростов-на-Дону – 2026

Оглавление

Постановка задачи	3
Введение	4
1. Описание полученных результатов	6
1.1. Разведочный анализ данных.....	6
1.2. Коллаборативная фильтрация на основе SVD.....	7
1.3. Контентная фильтрация на основе косинусного сходства	9
1.4. Результаты вычислений.....	10
Заключение.....	12
Литература.....	13

Постановка задачи

В рамках курсовой работы рассматривается задача построения рекомендательной системы для электронной коммерции на основе датасета оценок товаров платформы Amazon [1].

В рамках курсовой работы необходимо:

- 1) загрузить датасет и провести разведочный анализ данных (EDA);
- 2) реализовать метод коллаборативной фильтрации на основе матричной факторизации (SVD);
- 3) реализовать метод контентной фильтрации на основе косинусного сходства (cosine similarity);
- 4) реализовать гибридный подход, объединяющий оба метода;
- 5) сравнить качество методов с помощью метрик RMSE, MAE и Precision@K;
- 6) оформить отчёт о проделанной работе.

Введение

Рекомендательные системы являются одним из наиболее практически востребованных приложений машинного обучения. Они используются крупнейшими платформами электронной коммерции и стриминговых сервисов: Amazon, Netflix, Spotify, Wildberries — для персонализации пользовательского опыта и увеличения конверсии продаж.

Задача рекомендательной системы формально определяется следующим образом. Пусть задано множество пользователей $U = \{u_1, u_2, \dots, u_m\}$ и множество товаров $I = \{i_1, i_2, \dots, i_n\}$. Матрица оценок $R \in \mathbb{R}^{m \times n}$ содержит оценку r_{ui} , выставленную пользователем u товару i , либо пропуск, если оценка не выставлена. Цель системы — предсказать отсутствующие значения матрицы R и сформировать список рекомендаций для каждого пользователя.

В данной работе рассматриваются три подхода к построению рекомендательной системы.

Контентная фильтрация (Content-based filtering) основана на анализе характеристик товаров. Степень похожести двух товаров i и j вычисляется через косинусное сходство:

$$\text{sim}(i, j) = \cos(\theta) = \frac{\vec{v}_i \cdot \vec{v}_j}{\|\vec{v}_i\| \cdot \|\vec{v}_j\|} \quad (1)$$

где $\vec{v}_i$ и $\vec{v}_j$ — векторы признаков товаров i и j соответственно.

Коллаборативная фильтрация (Collaborative filtering) основана на анализе поведения похожих пользователей. Используется метод матричной факторизации SVD, который представляет матрицу оценок в виде:

$$R \approx P \Sigma Q^\top \quad (2)$$

где $P \in \mathbb{R}^{m \times k}$ — матрица пользователей, $Q \in \mathbb{R}^{n \times k}$ — матрица товаров, $\Sigma \in \mathbb{R}^{k \times k}$ — диагональная матрица сингулярных значений, k — число латентных факторов.

Гибридный подход объединяет оба метода путём взвешенного усреднения:

$$\hat{r}_{ui}^{\text{hybrid}} = \alpha \cdot \hat{r}_{ui}^{\text{CF}} + (1 - \alpha) \cdot \hat{r}_{ui}^{\text{CB}} \quad (3)$$

где $\hat{r}_{ui}^{\text{CF}}$ — предсказание коллаборативной фильтрации, $\hat{r}_{ui}^{\text{CB}}$ — предсказание контентной фильтрации, $\alpha \in [0, 1]$ — коэффициент смешивания, подбираемый экспериментально.

Для оценки качества используются метрики RMSE и Precision@K:

$$\text{RMSE} = \sqrt{\frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} (r_{ui} - \hat{r}_{ui})^2} \quad (4)$$

где $\mathcal{D}$ — тестовая выборка, r_{ui} — реальная оценка, $\hat{r}_{ui}$ — предсказанная оценка.

$$\text{Precision@K} = \frac{|\mathcal{R}_K|}{K} \quad (5)$$

где $\mathcal{R}_K$ — множество релевантных товаров среди топ- K рекомендаций (товар считается релевантным, если его реальная оценка не ниже 4).

Реализация выполнена на языке Python с использованием библиотек `pandas` [2], `scikit-learn` [3] и `surprise` [4].

1. Описание полученных результатов

1.1. Разведочный анализ данных

В работе использован датасет Amazon Beauty Ratings [1], содержащий оценки пользователей товаров категории «Красота и уход» платформы Amazon. Исходный датасет содержит 2 023 070 оценок, выставленных 1 210 271 пользователями для 249 274 товаров.

Для обеспечения качества модели была выполнена фильтрация: оставлены пользователи с не менее чем 5 оценками и товары с не менее чем 10 оценками. После фильтрации датасет содержит 350 229 оценок, 51 888 пользователей и 34 818 товаров.

На рисунке 1 представлено распределение оценок в датасете. Наблюдается выраженный перекос в сторону высоких оценок: 61.7% всех оценок составляют пятёрки. Данный эффект известен в литературе как *positivity bias* и типичен для платформ электронной коммерции.




Рис. 1. Распределение оценок в датасете Amazon Beauty

На рисунке 2 показано распределение активности пользователей и популярности товаров. Оба распределения следуют степенному закону. Разреженность матрицы оценок составляет 99.98%, что является типичным показателем для задач коллаборативной фильтрации.




Рис. 2. Активность пользователей и популярность товаров

В листинге 1 приведён код загрузки и анализа данных.

Листинг 1. Код разведочного анализа данных

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('ratings_Beauty.csv')
df.columns = ['user_id', 'product_id', 'rating', 'timestamp']

# Фильтрация
user_counts = df['user_id'].value_counts()
item_counts = df['product_id'].value_counts()
df_filtered = df[
    df['user_id'].isin(user_counts[user_counts >= 5].index) &
    df['product_id'].isin(item_counts[item_counts >= 10].index)
]
```

1.2. Коллаборативная фильтрация на основе SVD

Метод матричной факторизации SVD реализован с использованием библиотеки Surprise [4]. Матрица оценок разделена на обучающую (80%) и тестовую (20%) выборки: 280 183 и 70 046 оценок соответственно. Модель обучена с числом латентных факторов $k = 50$ и числом итераций $n_epochs = 20$.

На рисунке 3 показано соответствие реальных и предсказанных оценок. Точки группируются вертикальными полосами вследствие дискретности реальных оценок при непрерывности предсказаний модели.




Рис. 3. SVD: реальные против предсказанных оценок

Листинг 2. Код обучения модели SVD

```
from surprise import SVD, Dataset, Reader, accuracy
from surprise.model_selection import train_test_split

reader = Reader(rating_scale=(1, 5))
data = Dataset.load_from_df(
    df_filtered[['user_id', 'product_id', 'rating']], reader)
trainset, testset = train_test_split(data, test_size=0.2,
                                     random_state=42)

svd_model = SVD(n_factors=50, n_epochs=20, random_state=42)
svd_model.fit(trainset)
predictions = svd_model.test(testset)
```


1.3. Контентная фильтрация на основе косинусного сходства

Для контентной фильтрации построена матрица сходства товаров на основе профилей оценок пользователей по формуле (1). Поскольку датасет не содержит текстовых описаний товаров, в качестве вектора признаков товара использован столбец матрицы оценок.

Для вычислительной эффективности применялось разреженное представление матрицы (`scipy.sparse.csr_matrix`), что сократило объём используемой памяти с 13.5 ГБ до 2.7 МБ. Матрица сходства построена для 5 000 наиболее популярных товаров.

На рисунке 4 представлена тепловая карта матрицы сходства для топ-20 товаров. Тёмные клетки на диагонали соответствуют сходству товара с самим собой (равно 1.0).




Рис. 4. Матрица косинусного сходства топ-20 популярных товаров

Листинг 3. Код контентной фильтрации

```
from scipy.sparse import csr_matrix
from sklearn.metrics.pairwise import cosine_similarity
from sklearn.preprocessing import LabelEncoder

item_enc = LabelEncoder()
df_filtered['item_idx'] = item_enc.fit_transform(
    df_filtered['product_id'])

sparse_matrix = csr_matrix(
    (df_filtered['rating'].values,
     (df_filtered['item_idx'].values,
      df_filtered['user_idx'].values)))

top_items_idx = item_enc.transform(top_items_ids)
item_similarity = cosine_similarity(
    sparse_matrix[top_items_idx], dense_output=False)
```

1.4. Результаты вычислений

В таблице 1 представлены результаты сравнения методов. Для контентной фильтрации и гибридного подхода вычисление RMSE и MAE невозможно, поскольку эти методы не предсказывают числовые оценки напрямую.

Таблица 1. Сравнение методов рекомендательной системы

Метод	RMSE	MAE	Precision@10	Хол. старт
Коллаборативная (SVD)	1.1218	0.8659	0.1511	Проблема
Контентная (Cosine)	—	—	—	Решает
Гибридный подход	—	—	—	Частично
Baseline (среднее)	1.1923	0.9521	—	—

На рисунках 6 и 6 показано сравнение SVD с базовым методом по метрикам RMSE и MAE, а также зависимость Precision@K от числа рекомендаций K . Метод SVD превосходит базовый метод по обоим метрикам. Значение Precision@10 = 0.1511 означает, что 15.1% товаров из топ-10 рекомендаций реально оценены пользователем высоко.




Рис. 5. Сравнение методов: ошибки предсказания




Рис. 6. Сравнение методов: Precision@K

Заключение

В ходе выполнения курсовой работы были решены все поставленные задачи.

- 1) Загружен и проанализирован датасет Amazon Beauty Ratings, содержащий 2 023 070 оценок. Выявлен эффект positivity bias: 61.7% оценок составляют пятёрки. Разреженность матрицы оценок составила 99.98%.
- 2) Реализована коллаборативная фильтрация на основе SVD. Модель достигла $RMSE = 1.1218$ и $MAE = 0.8659$, превзойдя базовый метод ($RMSE = 1.1923$).
- 3) Реализована контентная фильтрация на основе косинусного сходства с применением разреженных матриц для вычислительной эффективности.
- 4) Реализован гибридный подход с весовым коэффициентом $\alpha = 0.5$.
- 5) Проведено сравнение методов. Значение $Precision@10 = 0.1511$ показывает, что каждая шестая рекомендация является релевантной.

Основным ограничением системы является высокая разреженность данных и проблема холодного старта для новых пользователей. В качестве направлений дальнейшего развития можно рассмотреть применение нейросетевых методов (Neural Collaborative Filtering) и обогащение признаков товаров текстовыми описаниями.

Литература

1. Amazon — Ratings (Beauty Products) [Электронный ресурс]. — URL: <https://www.kaggle.com/datasets/skillsmugger/amazon-ratings> (дата обращения: 20.04.2026)
2. Документация библиотеки pandas [Электронный ресурс]. — URL: <https://pandas.pydata.org/docs/> (дата обращения: 01.05.2026)
3. Документация библиотеки scikit-learn [Электронный ресурс]. — URL: <https://scikit-learn.org/stable/index.html> (дата обращения: 01.05.2026)
4. Документация библиотеки Surprise [Электронный ресурс]. — URL: <https://surpriselib.com/> (дата обращения: 01.05.2026)